

МОДЕЛИРОВАНИЕ ПЕРЕХОДНЫХ ПРОЦЕССОВ В RLC- КОНТУРЕ С ИСПОЛЬЗОВАНИЕМ ФИЗИКО- ИНФОРМИРОВАННЫХ НЕЙРОННЫХ СЕТЕЙ (PINN) С ЖЕСТКИМИ ОГРАНИЧЕНИЯМИ

[Текеева М.А., Левашев Т.Р., Наталичев Д.А., ИВТ-б-о-23-2 СКФУ]

АННОТАЦИЯ

В работе исследуется задача моделирования переходных процессов в последовательном RLC-контуре с помощью физико-информированных нейронных сетей (PINN) [1]. Стандартные PINN с мягкими ограничениями (Soft Constraints) сталкиваются с дисбалансом градиентов и катастрофическим ростом ошибки при экстраполяции. Предложена модификация архитектуры на основе жестких ограничений (Hard Constraints) [2] со специальным параметрическим анзацем, аналитически зануляющим ошибку начальных условий на уровне структуры выходного слоя. Обучение реализовано по гибридной схеме Adam + L-BFGS [3]. Эксперименты подтвердили строго физическое затухание колебаний в зоне прогноза и сохранение корректной топологии фазового портрета, что демонстрирует количественное и качественное превосходство над базовыми моделями PINN.

1 ВВЕДЕНИЕ

Физико-информированные нейронные сети (PINN) [1] стали перспективным инструментом моделирования динамических систем, включая переходные процессы в RLC-контурх. В отличие от классических архитектур, PINN интегрируют дифференциальные уравнения непосредственно в функцию потерь, что позволяет проводить вычисления с учётом фундаментальных физических законов.

Стандартная методология PINN опирается на мягкие ограничения (Soft Constraints), объединяя начальные условия (IC) и физическую невязку в единый многокритериальный функционал. Это порождает конфликт градиентов: оптимизатор разрывается между физикой уравнения и начальными точками, что приводит к слабой устойчивости и «взрыву» ошибки при экстраполяции. В работе исследуется метод жестких

ограничений [2], при котором начальные условия точно удовлетворяются на уровне архитектуры. Научная новизна заключается в сравнительном анализе математических структур анзаца: показан эффект «информационной избыточности» полностью детерминированного анзаца и предложен оригинальный параметрический анзац, где нейросеть оптимизирует динамическую амплитуду и фазовый сдвиг, а начальные условия гарантируются аналитическим фильтром.

2 МАТЕМАТИЧЕСКАЯ ПОСТАНОВКА ЗАДАЧИ

Рассматривается классическая задача о свободном разряде конденсатора в последовательном RLC-контуре. По второму закону Кирхгофа, с учётом $i(t) = \frac{dq}{dt}$:

$$L \frac{d^2 q(t)}{dt^2} + R \frac{dq(t)}{dt} + \frac{1}{C} q(t) = 0$$

Приведём уравнение к каноническому виду, разделив на L:

$$\frac{d^2 q(t)}{dt^2} + 2\gamma \frac{dq(t)}{dt} + \omega_0^2 q(t) = 0,$$

где $\gamma = \frac{R}{2L}$ – коэффициент затухания, $\omega_0 = \frac{1}{\sqrt{LC}}$ – собственная угловая частота контура. Начальные условия соответствуют полностью заряженному конденсатору при отсутствии тока: $q(0) = Q_0, \left. \frac{dq}{dt} \right|_{t=0} = 0$.

В режиме недодемпфирования ($\gamma < \omega_0$) система совершает затухающие гармонические колебания. В качестве эталона (Ground Truth) используется аналитическое решение:

$$q_{exact}(t) = Q_0 e^{-\gamma t} \left(\cos(\omega_d t) + \frac{\gamma}{\omega_d} \sin(\omega_d t) \right),$$

где $\omega_d = \sqrt{\omega_0^2 - \gamma^2}$ – частота свободных затухающих колебаний. Эту зависимость PINN восстанавливает в ходе оптимизации, опираясь только на структуру уравнения и начальные точки, без доступа к экспериментальным данным.

3 АРХИТЕКТУРА PINN И КОНСТРУИРОВАНИЕ ФИЗИЧЕСКОГО АНЗАЦА

3.1 Многослойный перцептрон и периодическая активация

Аппроксимирующим базисом служит полносвязный перцептрон (MLP), на вход которого подаётся нормализованное время $t_{norm} = \frac{t}{t_{max}}, \in [0, 1]$. Сеть содержит 5 скрытых линейных слоёв по 128 нейронов. В отличие от ReLU/Tanh, использована периодическая функция активации $Sine(x) = \sin(x)$, что сближает архитектуру с концепцией SIREN[4]:

$$x^{(l+1)} = \sin(W^{(l)}x^{(l)} + b^{(l)})$$

Выбор синусоиды обусловлен спецификой задачи: затухающие колебания имеют гармонический базис, $\sin(x)$ бесконечно дифференцируема, а её производные не затухают, что критично для корректного вычисления старших производных в Physics Loss. Веса инициализируются из $U(-10^{-2}, 10^{-2})$, смещения зануляются – это обеспечивает стабильный старт в линейной области синуса.

3.2 Принцип жестких ограничений и эволюция анзацев

Метод жестких ограничений (Hard Constraints)[2] пропускает выход сети через математический фильтр (анзац), трансформирующий абстрактный выход $f_{\theta}(t_{norm})$ в физическую величину $q_{pred}(t)$, строго удовлетворяющую $q(0) = Q_0$ и $\frac{dq}{dt}(0) = 0$. Исследованы три структуры анзаца.

1. Детерминированный (гибридный) анзац:

$$q_{pred}(t) = q_{base}(t) + t^2 \cdot e^{-\gamma t} \cdot f_{\theta}(t_{norm}),$$

где $q_{base}(t)$ – точное аналитическое решение. Анзац формально безупречен ($RMSE \approx 10^{-7}$), однако возникает «информационная избыточность»: оптимизатор зануляет веса ($f_{\theta} \rightarrow 0$), поскольку решение уже встроено в q_{base} . Сеть исключается из вычислений и теряет роль автономного аппроксиматора.

2. Простой экспоненциальный анзац:

$$q_{pred}(t) = Q_0 e^{-\gamma t} + (1 - e^{-t^2}) e^{-\gamma t} \cdot f_{\theta}(t_{norm}),$$

При $t \rightarrow 0$ множитель $(1 - e^{-t^2}) \rightarrow 0$, что жестко фиксирует $q(0) = Q_0$. Сеть восстанавливает колебания «с нуля», но из-за отсутствия частотного базиса оптимизатор застревает в локальных минимумах ландшафта потерь.

3. Оригинальный параметрический анзац (финальное решение):

Выходной слой генерирует два независимых параметра: динамическую амплитуду $A_{pred}(t)$ и фазовый сдвиг $\phi_{prd}(t)$. Итоговое уравнение PINN:

$$q_{pred}(t) = Q_0 e^{-\gamma t} + [1 + (1 - e^{-t^2}) \cdot A_{pred}(t) \cdot \cos(\omega_d t + \phi_{prd}(t))]$$

В структуру заложены фундаментальные законы затухания $e^{-\gamma t}$ и опорная частота ω_d . Сеть не «рисует» синусоиду, а динамически подстраивает амплитудные искажения и фазовые сдвиги. При $t = 0$ множитель $(1 - e^{-t^2})$ обращается в нуль, и $q_{pred}(0) = Q_0$ независимо от весов θ ; первая производная (ток) в начальной точке также автоматически зануляется.

3.3 Механизм автоматического дифференцирования (Autograd)

Производные предсказанного заряда вычисляются механизмом `torch.autograd` [5] по цепному правилу, без погрешности конечно-

разностных схем: $i_{pred}(t) = \frac{dq_{pred}}{dt} = \text{Autograd}(q_{pred}, t), \frac{d^2 q_{pred}}{dt^2} =$

$\text{Autograd}(i_{pred}, t)$. Полученные аналитически точные производные подставляются в каноническое уравнение RLC-контура для формирования физической невязки на коллокационной сетке.

4 СХЕМА ОПТИМИЗАЦИИ И ОРГАНИЗАЦИЯ ЭКСПЕРИМЕНТА

Временной интервал разделён на зоны интерполяции $t \in [0, 6.0]$ с и экстраполяции $t \in (6.0, 9.0]$ с. Функционал потерь сформирован по гибриднему принципу:

$$L_{total} = L_{data} + \lambda_{physics} \cdot L_{physics}$$

Компонент L_{data} – MSE отклонений предсказаний от разреженных опорных точек ($N_{data} = 50$ на интервале обучения), компонент $L_{physics}$ минимизирует невязку дифференциального уравнения на коллокационной сетке ($N_{coll} = 500$):

$$L_{data} = \frac{1}{N_{data}} \sum_{i=1}^{N_{data}} (q_{pred}(t_i) - q_{data}(t_i))^2,$$

$$L_{physics} = \frac{1}{N_{coll}} \sum_{j=1}^{N_{coll}} \left(\frac{d^2 q_{pred}(t_j)}{dt^2} + 2\gamma \frac{dq_{pred}(t_j)}{dt} + \omega_0^2 q_{pred}(t_j) \right)^2,$$

Весовой коэффициент $\lambda_{physics}$ динамически масштабировался (0.01 на старте и 0.1 после 1000 эпох) для компенсации жесткости градиентов. Использована двухэтапная стратегия: предварительная оптимизация Adam для поиска общей формы волны и финальная доводка квазиньютоновским методом L-BFGS [3].

5 РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТА И СРАВНИТЕЛЬНЫЙ АНАЛИЗ

Тестирование проводилось на независимой равномерной сетке из $N_{test} = 750$ точек, охватывающей обе зоны. Сводные количественные показатели представлены в таблице 1.

Таблица 1 – Сравнительный анализ точности моделей PINN

Модель (тип анзаца)	Relative L_2	Max Error	RMSE	MSR ($L_{physics}$)
№1 – Детерминированный	0.000001	0.000001	0.000000	0.000000
№2 – Простой экспоненциальный	0.884106	0.787116	0.388781	1.628844
№3 – Параметрический	0.090170	0.088555	0.039652	0.030979

5.1 Анализ динамики обучения и сходимости моделей

Анзац №1 показал околонулевые погрешности на всех метриках, однако это «вырожденный» успех: при встроенном в фильтр точном решении оптимизатор мгновенно зануляет веса нейросетевой компоненты – сеть фактически исключается из вычислений и теряет ценность автономного аппроксиматора. Анзац №2 ($Relative L_2 \approx 88.4\%$, $MSR \approx 1.63$) демонстрирует полную вычислительную несостоятельность: кривая теряет фазу и затухает некорректно, поскольку ландшафт потерь для чисто гармонических функций сильно невыпуклый и градиентные методы застревают в локальных минимумах, не способных самостоятельно определить ω_d . Параметрический анзац №3 ($Relative L_2 \approx 9.0\%$, $RMSE \approx 0.040$) преодолевает оба недостатка: благодаря заложенному физическому

каркасу частоты и затухания сеть фокусируется на поиске гладких макропараметров – амплитуды $A_{pred}(t)$ и фазы $\varphi_{pred}(t)$.

5.2 Физическая состоятельность параметрической модели (Анзац №3)

Динамика заряда (рис. 1) демонстрирует практически идеальное совпадение PINN с эталоном в зоне обучения $t \in [0; 6.0]$ с. В зоне чистой экстраполяции, где опорные точки отсутствуют, сеть устойчиво сохраняет физическую структуру затухающих колебаний – параметрический фильтр предотвратил экспоненциальный разгон ошибки, характерный для стандартных нейросетевых экстраполяторов.




Рисунок 1 – Динамика заряда $q(t)$ с зоной экстраполяции для Анзаца №3

График истории обучения (рис. 2) наглядно иллюстрирует эффективность двухэтапной стратегии оптимизации: на этапе Adam (первые 1000 эпох) наблюдается интенсивное снижение лосса, затем L-BFGS обеспечивает «снайперскую» полировку, вызывая мгновенное ступенчатое падение физической невязки $L_{physics}$ до уровня 10^{-3} .




Рисунок 2 – История сходимости функции потерь для Анзаца №3

Фазовый портрет (рис. 3) принимает вид классической скручивающейся спирали, стремящейся к началу координат $(0, 0)$, что доказывает корректное воспроизведение диссипативных свойств среды – закон сохранения энергии в замкнутом контуре строго соблюдается.




Рисунок 3 – Фазовый портрет (зависимость $i(t)$ от $q(t)$) для Анзаца №3

График абсолютной ошибки (рис. 4) подтверждает высокую локальную точность: в зоне обучения погрешность не превышает 0.01, в зоне экстраполяции достигает максимума 0.088 на краю интервала – этот скачок обусловлен микросдвигом фазы и укладывается в инженерные допуски обратных задач. Распределение остатка ДУ во времени (рис. 5) равномерно колеблется около нулевой отметки на всём промежутке, без выраженных пиков на границе $t = 6.0$ с, что подтверждает одинаково эффективное удовлетворение физическому закону как в присутствии данных, так и в режиме чистого прогноза.




Рисунок 4 – Абсолютная ошибка предсказания заряда для Анзаца №3




Рисунок 5 – Остаток дифференциального уравнения для Анзаца №3

5.3 Сравнительный анализ траекторий исследованных архитектур

Сопоставление траекторий заряда трёх архитектур (рис. 6) демонстрирует превосходство параметрической модели: Анзац №1 тривиально вырождается в аналитическую формулу (сеть не обучается), траектория Анзаца №2 уходит в противофазу и демонстрирует некорректную частоту колебаний из-за застревания в локальном минимуме, и только параметрическая модель (Анзац №3) является вычислительно устойчивым решением, способным к автономному извлечению макропараметров системы.




Рисунок 6 – Динамика заряда $q(t)$ для трёх анзацев

Сравнительный фазовый портрет трёх архитектур (рис. 7) наглядно подтверждает вырождение Анзаца №1 и полную потерю физической адекватности траектории Анзаца №2, тогда как параметрическая модель точно воспроизводит канонический диссипативный аттрактор.




Рисунок 7 – Фазовый портрет для трёх анзацев

Сравнение абсолютной ошибки предсказания заряда трёх архитектур (рис. 8) подтверждает выводы таблицы 1: погрешность Анзаца №2 нарастает экспоненциально в зоне экстраполяции, тогда как Анзац №3 удерживает абсолютную ошибку в пределах инженерных допусков на всём временном интервале.




Рисунок 8 – Абсолютная ошибка предсказания заряда для трёх анзацев

Остаток дифференциального уравнения (рис. 9) для Анзаца №2 демонстрирует крупные нарастающие осцилляции невязки в зоне экстраполяции, тогда как Анзац №3 удерживает невязку Кирхгофа в узком околонулевом коридоре по всему временному интервалу.




Рисунок 9 – Остаток дифференциального уравнения для трёх анзацев

ЗАКЛЮЧЕНИЕ

Реализованы и верифицированы методы физико-информированного машинного обучения для моделирования переходных процессов в RLC-контуре. Эксперимент выявил критические уязвимости стандартных подходов: экспоненциальный фильтр без частотного базиса (Анзац №2) приводит к потере фазы и росту ошибки более 88% в зоне экстраполяции, тогда как избыточная аналитическая детерминация (Анзац №1) вызывает тривиальное вырождение весов.

Наиболее устойчивым решением оказалась предложенная параметрическая архитектура с разделением выходов сети на динамическую амплитуду и фазу (Анзац №3), обеспечившая $RMSE = 0.0397$ и удержание невязки уравнения Кирхгофа в околонулевом коридоре. В режиме чистой экстраполяции максимальная абсолютная погрешность ограничена уровнем 0.088, энергетическая структура диссипативного процесса на фазовом портрете воспроизведена в виде канонического скручивающегося аттрактора. Предложенная модификация PINN подавляет градиентные аномалии оптимизатора L-BFGS и гарантирует устойчивость численного прогнозирования, открывая перспективы сквозного моделирования радиотехнических систем в условиях разреженных и зашумлённых данных.

Исходный код проекта доступен по ссылке:
<https://github.com/mazy99/pinn-rlc-circuit>

СПИСОК ЛИТЕРАТУРЫ

1. Raissi, M. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations / M. Raissi, P. Perdikaris, G. E. Karniadakis // Journal of Computational Physics. — 2019. — Vol. 378. — P. 686–707.
2. Lagaris, I. E. Artificial neural networks for solving ordinary and partial differential equations / I. E. Lagaris, A. Likas, D. I. Fotiadis // IEEE Transactions on Neural Networks. — 1998. — Vol. 9, № 5. — P. 987–1000.
3. Liu, D. C. On the limited memory BFGS method for large scale optimization / D. C. Liu, J. Nocedal // Mathematical Programming. — 1989. — Vol. 45, № 1–3. — P. 503–528.
4. Sitzmann, V. Implicit Neural Representations with Periodic Activation Functions / V. Sitzmann, J. Martel, A. Bergman, D. Lindell, G. Wetzstein // Advances in Neural Information Processing Systems (NeurIPS 2020). — 2020. — Vol. 33. — P. 7493–7505.

5. PyTorch: Paszke A. et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*, NeurIPS 2019.