

# **МОДЕЛИРОВАНИЕ ПЕРЕХОДНЫХ ПРОЦЕССОВ В RLC- КОНТУРЕ С ИСПОЛЬЗОВАНИЕМ ФИЗИКО- ИНФОРМИРОВАННЫХ НЕЙРОННЫХ СЕТЕЙ (PINN) С ЖЕСТКИМИ ОГРАНИЧЕНИЯМИ**

*[Текеева М.А., Левашев Т.Р., Наталичев Д.А., ИВТ-б-о-23-2 СКФУ]*

## **АННОТАЦИЯ**

В работе исследуется задача моделирования переходных процессов в последовательном RLC-контуре с помощью физико-информированных нейронных сетей (PINN) [1]. Стандартные PINN с мягкими ограничениями (Soft Constraints) сталкиваются с дисбалансом градиентов и катастрофическим ростом ошибки при экстраполяции. Предложена модификация архитектуры на основе жестких ограничений (Hard Constraints) [2] со специальным параметрическим анзацем, аналитически зануляющим ошибку начальных условий на уровне структуры выходного слоя. Обучение реализовано по гибридной схеме Adam + L-BFGS [3]. Эксперименты подтвердили строго физическое затухание колебаний в зоне прогноза и сохранение корректной топологии фазового портрета, что демонстрирует количественное и качественное превосходство над базовыми моделями PINN.

## **1 ВВЕДЕНИЕ**

Физико-информированные нейронные сети (PINN) [1] стали перспективным инструментом моделирования динамических систем, включая переходные процессы в RLC-контурх. В отличие от классических архитектур, PINN интегрируют дифференциальные уравнения непосредственно в функцию потерь, что позволяет проводить вычисления с учётом фундаментальных физических законов.

Стандартная методология PINN опирается на мягкие ограничения (Soft Constraints), объединяя начальные условия (IC) и физическую невязку в единый многокритериальный функционал. Это порождает конфликт градиентов: оптимизатор разрывается между физикой уравнения и начальными точками, что приводит к слабой устойчивости и «взрыву» ошибки при экстраполяции. В работе исследуется метод жестких

ограничений [2], при котором начальные условия точно удовлетворяются на уровне архитектуры. Научная новизна заключается в сравнительном анализе математических структур анзаца: показан эффект «информационной избыточности» полностью детерминированного анзаца и предложен оригинальный параметрический анзац, где нейросеть оптимизирует динамическую амплитуду и фазовый сдвиг, а начальные условия гарантируются аналитическим фильтром.

## 2 МАТЕМАТИЧЕСКАЯ ПОСТАНОВКА ЗАДАЧИ

Рассматривается классическая задача о свободном разряде конденсатора в последовательном RLC-контуре. По второму закону Кирхгофа, с учётом  $i(t) = \frac{dq}{dt}$ :

$$L \frac{d^2 q(t)}{dt^2} + R \frac{dq(t)}{dt} + \frac{1}{C} q(t) = 0$$

Приведём уравнение к каноническому виду, разделив на L:

$$\frac{d^2 q(t)}{dt^2} + 2\gamma \frac{dq(t)}{dt} + \omega_0^2 q(t) = 0,$$

где  $\gamma = \frac{R}{2L}$  – коэффициент затухания,  $\omega_0 = \frac{1}{\sqrt{LC}}$  – собственная угловая частота контура. Начальные условия соответствуют полностью заряженному конденсатору при отсутствии тока:  $q(0) = Q_0, \left. \frac{dq}{dt} \right|_{t=0} = 0$ .

В режиме недодемпфирования ( $\gamma < \omega_0$ ) система совершает затухающие гармонические колебания. В качестве эталона (Ground Truth) используется аналитическое решение:

$$q_{exact}(t) = Q_0 e^{-\gamma t} \left( \cos(\omega_d t) + \frac{\gamma}{\omega_d} \sin(\omega_d t) \right),$$

где  $\omega_d = \sqrt{\omega_0^2 - \gamma^2}$  – частота свободных затухающих колебаний. Эту зависимость PINN восстанавливает в ходе оптимизации, опираясь только на структуру уравнения и начальные точки, без доступа к экспериментальным данным.

## 3 АРХИТЕКТУРА PINN И КОНСТРУИРОВАНИЕ ФИЗИЧЕСКОГО АНЗАЦА

### 3.1 Многослойный перцептрон и периодическая активация

Аппроксимирующим базисом служит полносвязный перцептрон (MLP), на вход которого подаётся нормализованное время  $t_{norm} = \frac{t}{t_{max}}, \in [0, 1]$ . Сеть содержит 5 скрытых линейных слоёв по 128 нейронов. В отличие от ReLU/Tanh, использована периодическая функция активации  $Sine(x) = \sin(x)$ , что сближает архитектуру с концепцией SIREN[4]:

$$x^{(l+1)} = \sin(W^{(l)}x^{(l)} + b^{(l)})$$

Выбор синусоиды обусловлен спецификой задачи: затухающие колебания имеют гармонический базис,  $\sin(x)$  бесконечно дифференцируема, а её производные не затухают, что критично для корректного вычисления старших производных в Physics Loss. Веса инициализируются из  $U(-10^{-2}, 10^{-2})$ , смещения зануляются – это обеспечивает стабильный старт в линейной области синуса.

### 3.2 Принцип жестких ограничений и эволюция анзацев

Метод жестких ограничений (Hard Constraints)[2] пропускает выход сети через математический фильтр (анзац), трансформирующий абстрактный выход  $f_{\theta}(t_{norm})$  в физическую величину  $q_{pred}(t)$ , строго удовлетворяющую  $q(0) = Q_0$  и  $\frac{dq}{dt}(0) = 0$ . Исследованы три структуры анзаца.

1. Детерминированный (гибридный) анзац:

$$q_{pred}(t) = q_{base}(t) + t^2 \cdot e^{-\gamma t} \cdot f_{\theta}(t_{norm}),$$

где  $q_{base}(t)$  – точное аналитическое решение. Анзац формально безупречен ( $RMSE \approx 10^{-7}$ ), однако возникает «информационная избыточность»: оптимизатор зануляет веса ( $f_{\theta} \rightarrow 0$ ), поскольку решение уже встроено в  $q_{base}$ . Сеть исключается из вычислений и теряет роль автономного аппроксиматора.

2. Простой экспоненциальный анзац:

$$q_{pred}(t) = Q_0 e^{-\gamma t} + (1 - e^{-t^2}) e^{-\gamma t} \cdot f_{\theta}(t_{norm}),$$

При  $t \rightarrow 0$  множитель  $(1 - e^{-t^2}) \rightarrow 0$ , что жестко фиксирует  $q(0) = Q_0$ . Сеть восстанавливает колебания «с нуля», но из-за отсутствия частотного базиса оптимизатор застревает в локальных минимумах ландшафта потерь.

3. Оригинальный параметрический анзац (финальное решение):

Выходной слой генерирует два независимых параметра: динамическую амплитуду  $A_{pred}(t)$  и фазовый сдвиг  $\phi_{prd}(t)$ . Итоговое уравнение PINN:

$$q_{pred}(t) = Q_0 e^{-\gamma t} + [1 + (1 - e^{-t^2}) \cdot A_{pred}(t) \cdot \cos(\omega_d t + \phi_{prd}(t))]$$

В структуру заложены фундаментальные законы затухания  $e^{-\gamma t}$  и опорная частота  $\omega_d$ . Сеть не «рисует» синусоиду, а динамически подстраивает амплитудные искажения и фазовые сдвиги. При  $t = 0$  множитель  $(1 - e^{-t^2})$  обращается в нуль, и  $q_{pred}(0) = Q_0$  независимо от весов  $\theta$ ; первая производная (ток) в начальной точке также автоматически зануляется.

### 3.3 Механизм автоматического дифференцирования (Autograd)

Производные предсказанного заряда вычисляются механизмом `torch.autograd` [5] по цепному правилу, без погрешности конечно-

разностных схем:  $i_{pred}(t) = \frac{dq_{pred}}{dt} = \text{Autograd}(q_{pred}, t)$ ,  $\frac{d^2 q_{pred}}{dt^2} =$

$\text{Autograd}(i_{pred}, t)$ . Полученные аналитически точные производные подставляются в каноническое уравнение RLC-контура для формирования физической невязки на коллокационной сетке.

## 4 СХЕМА ОПТИМИЗАЦИИ И ОРГАНИЗАЦИЯ ЭКСПЕРИМЕНТА

Временной интервал разделён на зоны интерполяции  $t \in [0, 6.0]$  с и экстраполяции  $t \in (6.0, 9.0]$  с. Функционал потерь сформирован по гибриднему принципу:

$$L_{total} = L_{data} + \lambda_{physics} \cdot L_{physics}$$

Компонент  $L_{data}$  – MSE отклонений предсказаний от разреженных опорных точек ( $N_{data} = 50$  на интервале обучения), компонент  $L_{physics}$  минимизирует невязку дифференциального уравнения на коллокационной сетке ( $N_{coll} = 500$ ):

$$L_{data} = \frac{1}{N_{data}} \sum_{i=1}^{N_{data}} (q_{pred}(t_i) - q_{data}(t_i))^2,$$

$$L_{physics} = \frac{1}{N_{coll}} \sum_{j=1}^{N_{coll}} \left( \frac{d^2 q_{pred}(t_j)}{dt^2} + 2\gamma \frac{dq_{pred}(t_j)}{dt} + \omega_0^2 q_{pred}(t_j) \right)^2,$$

Весовой коэффициент  $\lambda_{physics}$  динамически масштабировался (0.01 на старте и 0.1 после 1000 эпох) для компенсации жесткости градиентов. Использована двухэтапная стратегия: предварительная оптимизация Adam для поиска общей формы волны и финальная доводка квазиньютоновским методом L-BFGS [3].

## 5 РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТА И СРАВНИТЕЛЬНЫЙ АНАЛИЗ

Тестирование проводилось на независимой равномерной сетке из  $N_{test} = 750$  точек, охватывающей обе зоны. Сводные количественные показатели представлены в таблице 1.

Таблица 1 – Сравнительный анализ точности моделей PINN

| Модель (тип анзаца)           | Relative $L_2$ | Max Error | RMSE     | MSR<br>( $L_{physics}$ ) |
|-------------------------------|----------------|-----------|----------|--------------------------|
| №1 – Детерминированный        | 0.000001       | 0.000001  | 0.000000 | 0.000000                 |
| №2 – Простой экспоненциальный | 0.884106       | 0.787116  | 0.388781 | 1.628844                 |
| №3 – Параметрический          | 0.090170       | 0.088555  | 0.039652 | 0.030979                 |

### 5.1 Анализ динамики обучения и сходимости моделей

Анзац №1 показал околонулевые погрешности на всех метриках, однако это «вырожденный» успех: при встроенном в фильтр точном решении оптимизатор мгновенно зануляет веса нейросетевой компоненты – сеть фактически исключается из вычислений и теряет ценность автономного аппроксиматора. Анзац №2 ( $Relative L_2 \approx 88.4\%$ ,  $MSR \approx 1.63$ ) демонстрирует полную вычислительную несостоятельность: кривая теряет фазу и затухает некорректно, поскольку ландшафт потерь для чисто гармонических функций сильно невыпуклый и градиентные методы застревают в локальных минимумах, не способных самостоятельно определить  $\omega_d$ . Параметрический анзац №3 ( $Relative L_2 \approx 9.0\%$ ,  $RMSE \approx 0.040$ ) преодолевает оба недостатка: благодаря заложенному физическому

каркасу частоты и затухания сеть фокусируется на поиске гладких макропараметров – амплитуды  $A_{pred}(t)$  и фазы  $\varphi_{pred}(t)$ .

## 5.2 Физическая состоятельность параметрической модели (Анзац №3)

Динамика заряда (рис. 1) демонстрирует практически идеальное совпадение PINN с эталоном в зоне обучения  $t \in [0; 6.0]$  с. В зоне чистой экстраполяции, где опорные точки отсутствуют, сеть устойчиво сохраняет физическую структуру затухающих колебаний – параметрический фильтр предотвратил экспоненциальный разгон ошибки, характерный для стандартных нейросетевых экстраполяторов.




Рисунок 1 – Динамика заряда  $q(t)$  с зоной экстраполяции для Анзаца №3

График истории обучения (рис. 2) наглядно иллюстрирует эффективность двухэтапной стратегии оптимизации: на этапе Adam (первые 1000 эпох) наблюдается интенсивное снижение лосса, затем L-BFGS обеспечивает «снайперскую» полировку, вызывая мгновенное ступенчатое падение физической невязки  $L_{physics}$  до уровня  $10^{-3}$ .




Рисунок 2 – История сходимости функции потерь для Анзаца №3

Фазовый портрет (рис. 3) принимает вид классической скручивающейся спирали, стремящейся к началу координат  $(0, 0)$ , что доказывает корректное воспроизведение диссипативных свойств среды – закон сохранения энергии в замкнутом контуре строго соблюдается.




Рисунок 3 – Фазовый портрет (зависимость  $i(t)$  от  $q(t)$ ) для Анзаца №3

График абсолютной ошибки (рис. 4) подтверждает высокую локальную точность: в зоне обучения погрешность не превышает 0.01, в зоне экстраполяции достигает максимума 0.088 на краю интервала – этот скачок обусловлен микросдвигом фазы и укладывается в инженерные допуски обратных задач. Распределение остатка ДУ во времени (рис. 5) равномерно колеблется около нулевой отметки на всём промежутке, без выраженных пиков на границе  $t = 6.0$  с, что подтверждает одинаково эффективное удовлетворение физическому закону как в присутствии данных, так и в режиме чистого прогноза.




Рисунок 4 – Абсолютная ошибка предсказания заряда для Анзаца №3




Рисунок 5 – Остаток дифференциального уравнения для Анзаца №3

### 5.3 Сравнительный анализ траекторий исследованных архитектур

Сопоставление траекторий заряда трёх архитектур (рис. 6) демонстрирует превосходство параметрической модели: Анзац №1 тривиально вырождается в аналитическую формулу (сеть не обучается), траектория Анзаца №2 уходит в противофазу и демонстрирует некорректную частоту колебаний из-за застревания в локальном минимуме, и только параметрическая модель (Анзац №3) является вычислительно устойчивым решением, способным к автономному извлечению макропараметров системы.




Рисунок 6 – Динамика заряда  $q(t)$  для трёх анзацев

Сравнительный фазовый портрет трёх архитектур (рис. 7) наглядно подтверждает вырождение Анзаца №1 и полную потерю физической адекватности траектории Анзаца №2, тогда как параметрическая модель точно воспроизводит канонический диссипативный аттрактор.




Рисунок 7 – Фазовый портрет для трёх анзацев

Сравнение абсолютной ошибки предсказания заряда трёх архитектур (рис. 8) подтверждает выводы таблицы 1: погрешность Анзаца №2 нарастает экспоненциально в зоне экстраполяции, тогда как Анзац №3 удерживает абсолютную ошибку в пределах инженерных допусков на всём временном интервале.




Рисунок 8 – Абсолютная ошибка предсказания заряда для трёх анзацев

Остаток дифференциального уравнения (рис. 9) для Анзаца №2 демонстрирует крупные нарастающие осцилляции невязки в зоне экстраполяции, тогда как Анзац №3 удерживает невязку Кирхгофа в узком околонулевом коридоре по всему временному интервалу.




Рисунок 9 – Остаток дифференциального уравнения для трёх анзацев

## ЗАКЛЮЧЕНИЕ

Реализованы и верифицированы методы физико-информированного машинного обучения для моделирования переходных процессов в RLC-контуре. Эксперимент выявил критические уязвимости стандартных подходов: экспоненциальный фильтр без частотного базиса (Анзац №2) приводит к потере фазы и росту ошибки более 88% в зоне экстраполяции, тогда как избыточная аналитическая детерминация (Анзац №1) вызывает тривиальное вырождение весов.

Наиболее устойчивым решением оказалась предложенная параметрическая архитектура с разделением выходов сети на динамическую амплитуду и фазу (Анзац №3), обеспечившая  $RMSE = 0.0397$  и удержание невязки уравнения Кирхгофа в околонулевом коридоре. В режиме чистой экстраполяции максимальная абсолютная погрешность ограничена уровнем 0.088, энергетическая структура диссипативного процесса на фазовом портрете воспроизведена в виде канонического скручивающегося аттрактора. Предложенная модификация PINN подавляет градиентные аномалии оптимизатора L-BFGS и гарантирует устойчивость численного прогнозирования, открывая перспективы сквозного моделирования радиотехнических систем в условиях разреженных и зашумлённых данных.

## СПИСОК ЛИТЕРАТУРЫ

1. Raissi, M. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations / M. Raissi, P. Perdikaris, G. E. Karniadakis // Journal of Computational Physics. — 2019. — Vol. 378. — P. 686–707.
2. Lagaris, I. E. Artificial neural networks for solving ordinary and partial differential equations / I. E. Lagaris, A. Likas, D. I. Fotiadis // IEEE Transactions on Neural Networks. — 1998. — Vol. 9, № 5. — P. 987–1000.
3. Liu, D. C. On the limited memory BFGS method for large scale optimization / D. C. Liu, J. Nocedal // Mathematical Programming. — 1989. — Vol. 45, № 1–3. — P. 503–528.
4. Sitzmann, V. Implicit Neural Representations with Periodic Activation Functions / V. Sitzmann, J. Martel, A. Bergman, D. Lindell, G. Wetzstein // Advances in Neural Information Processing Systems (NeurIPS 2020). — 2020. — Vol. 33. — P. 7493–7505.
5. PyTorch: Paszke A. et al. *PyTorch: An Imperative Style, High-Performance Deep Learning Library*, NeurIPS 2019.